


Memoria *cache*: moduri de organizare

1. Principiul de funcționare al memoriei *cache*



Principiul localizării are două componente:

- localizarea temporală (localizarea în timp). Odată referite, anumite locații de memorie vor fi foarte probabil referite din nou, în viitorul apropiat.
- localizarea spațială (localizarea în spațiu). Referințele la memorie se fac cel mai adesea în apropierea (vecinătatea) ultimei locații referite.

1. Principiul de funcționare al memoriei *cache*

Exploatarea avantajelor localizării temporale:

Timpul mediu de acces la instrucțiunile unei bucle (parcursă la prima iterație din MP și la următoarele $n-1$ din *cache*):

$$\text{Timp mediu de acces} = \frac{(n \cdot t_c + t_m)}{n} = t_c + \frac{t_m}{n}$$

Exploatarea avantajelor localizării spațiale:


Implică interfațarea *cache*-ului cu ***m*** module de memorie; ***m*** se obține din ecuația de echilibru:

$$m \cdot t_c = t_m$$

Se va obține un plus de performanță pe prima iterație a buclei:

$$\text{Timp mediu de acces} = \frac{2 \cdot t_c + (n-1) \cdot t_c}{n} = \frac{(n+1) \cdot t_c}{n}$$

1. Principiul de funcționare al memoriei *cache*



Exploatarea avantajelor localizării spațiale
(*cache* interfațat cu 8 module de memorie principală)

2. Rata de *hit* (h)

$$h = \frac{\text{Numarul de referinte la memorie cu hit in cache}}{\text{Numarul total de referinte la memorie}}$$

Rata de *hit* (h) reprezintă și probabilitatea ca un cuvânt să fie găsit în *cache*.
Prin urmare, rata de *miss* este: $1 - h$.

Timpul mediu de acces la memorie (t_a), în funcție de rata de hit:

$$t_a = t_c + (1-h) \cdot t_m$$

Considerând: $t_c = t_{ci}$ (timp interogare *cache*) + t_{cr} (timp citire din *cache*), rezultă:

$$t_a = t_{ci} + h \cdot t_{cr} + (1-h) \cdot t_m$$


$$\text{sau: } t_a = h \cdot (t_{ci} + t_{cr}) + (1-h) \cdot (t_{ci} + t_m) \quad \begin{array}{l} t_{ci} + t_{cr} - \text{timp de hit} \\ t_{ci} + t_m - \text{timp de miss} \end{array}$$

$$\text{sau: } t_a = t_{ci} + t_{cr} + (1-h) \cdot (t_m - t_{cr})$$


$$t_{ci} + t_{cr} = t_{hit} \quad (\text{timpul de acces când data se află în } cache)$$

$$t_m - t_{cr} = t_{miss-pen} \quad (\text{timpul suplimentar care se adaugă (miss penalty) atunci când data nu se află în } cache)$$


3. Memoria *cache* complet asociativă (*fully associative cache*)




3. *Fully associative cache* cu linii multicuvânt



4. Memoria *cache* cu mapare directă



4. Memoria *cache* cu mapare directă cu linii multicuvânt



4. Memoria *cache* cu mapare directă

Avantajele mapării directe:

- Nu necesită algoritm de înlocuire (evacuare)
- *Hardware* simplu și cost scăzut
- Viteză mare de operare

Dezavantajele mapării directe:


- Performanțele scad considerabil dacă în aceeași perioadă de timp se accesează adrese MP diferite dar care prezintă câmpuri *index* identice.
- Rata de *hit* este mai mică decât în cazul *cache*-urilor asociative.

5. Memoria *cache* organizată în seturi asociative

Adresa MP emisă de procesor

Tag	Index	Word
-----	-------	------

(four-way set associative cache)



6. Cache-uri separate de instrucțiuni și respectiv de date

